

Bayesian statistics

Mô Hình Hồi Quy Bayesian

Khương Quỳnh Long


Hà Nội, 08/2019

<https://gitlab.com/LongKhuong/adhere-bayesian-statistics>

Nội dung

- ▶ So sánh sự khác biệt giữa “Classical model” và Bayesian model
- ▶ Markov Chain Monte Carlo
- ▶ Hàm loss và decision making
- ▶ Một số phần mềm sử dụng trong Bayesian

“Classical model”



Maximum Likelihood Estimation


$$y = \theta_0 + \theta_1 x + \varepsilon$$

Fixed


$\sim N(0, \sigma^2)$

- ▶ Tham số mô hình là **cố định** (point estimate)
- ▶ Dựa **hoàn toàn** vào likelihood của dữ liệu

Bayesian model



Prior cho δ^2




δ^2 (Scale)



$$y = \theta_0 + \theta_1 x + \varepsilon$$

ν, τ (Shape)



μ (Location)

Prior cho μ

$\sim N(\mu, \delta)$

$\sim t(\nu, \mu, \delta)$



Tham số cho Prior
được gọi là
“Hyperparameters”

Markov Chain Monte Carlo

Likelihood

Độ khả dĩ của dữ liệu: Xác suất thu thập được dữ liệu dưới điều kiện giả thuyết H đúng (Đơn giản là dữ liệu thu thập)

Prior

Xác suất tiền định: Xác suất giả thuyết H mà chúng ta tin là xảy ra (đúng) trước khi thu thập dữ liệu

$$P(H|D) = \frac{P(D|H) * P(H)}{P(D)}$$

Posterior

Xác xuất hậu định: Cần tìm Xác suất giả thuyết H đúng cho bởi dữ liệu thu thập

Marginal likelihood (normalizing constant)



Hằng số: Xác suất của dữ liệu (tổng tất cả **likelihood*****prior** của tất cả các giả thuyết có khả năng xảy ra)

MCMC

- ▶ Thuật toán dạng mô phỏng
- ▶ Có nhiều phương pháp sử dụng trong Bayesian:
Metropolis–Hastings, Gibbs, Hamiltonian Monte Carlo (HMC), No-U Turn Sampler (NUTS)...
- ▶ Metropolis–Hastings

Các hòn đảo có số dân khác nhau...

Vòng quay cân bằng từ 0 - 1
P(spin)



Nếu hòn đảo định tới có số dân lớn hơn hòn đảo hiện tại → **đi**

Nếu nhỏ hơn. Tính $P(\text{move}) = \text{Dân số (proposed)} / \text{Dân số (current)}$

Nếu $P(\text{move}) > P(\text{spin}) \rightarrow$ **đi**

Nếu không, **ở lại thêm** 1 ngày....



Số ngày ở lại mỗi hòn đảo ~ số dân của hòn đảo đó !!!


Metropolis-Hastings

- ▶ Mô phỏng Monte Carlo
- ▶ Markov process
- ▶ Metropolis-Hastings algorithms

“Random walk”

$$P(\theta | \text{Data}) = \frac{P(\text{Data} | \theta) * P(\theta)}{P(\text{Data})}$$


Monte Carlo



Trace plot

Draw $\theta_t \sim \text{Normal}(0.5, \sigma) = 0.549$

Markov process




Random walk

Draw $\theta_t \sim \text{Normal}(\theta_{t-1}, \sigma)$

$\text{Normal}(0.460, \sigma) = 0.621$

Giá trị trung bình của phân phối ở vòng lặp sau chính bằng giá trị θ vừa lấy từ vòng lặp trước

Metropolis-Hastings algorithms



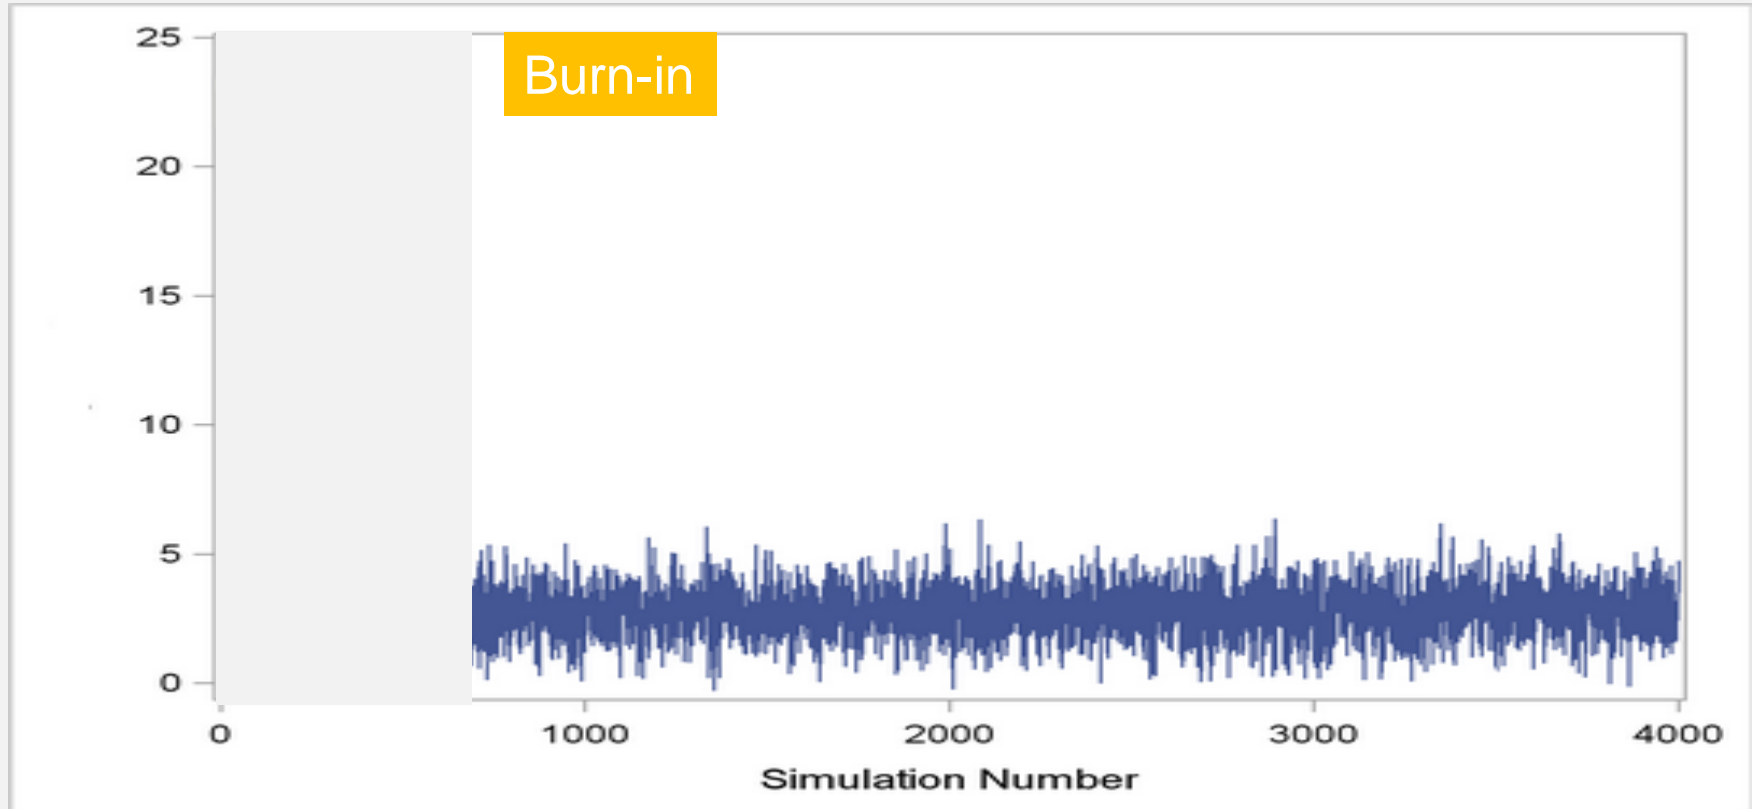
$$\text{Step 1: } r(\theta_{\text{new}}, \theta_{t-1}) = \frac{\text{Posterior}(\theta_{\text{new}})}{\text{Posterior}(\theta_{t-1})} = \frac{\text{Beta}(1,1,0.767) \times \text{Binomial}(10,4,0.767)}{\text{Beta}(1,1,0.540) \times \text{Binomial}(10,4,0.540)} = 0.069$$

$$\text{Step 2: Acceptance probability } \alpha(\theta_{\text{new}}, \theta_{t-1}) = \min\{r(\theta_{\text{new}}, \theta_{t-1}), 1\} = \min\{0.069, 1\} = 0.069$$

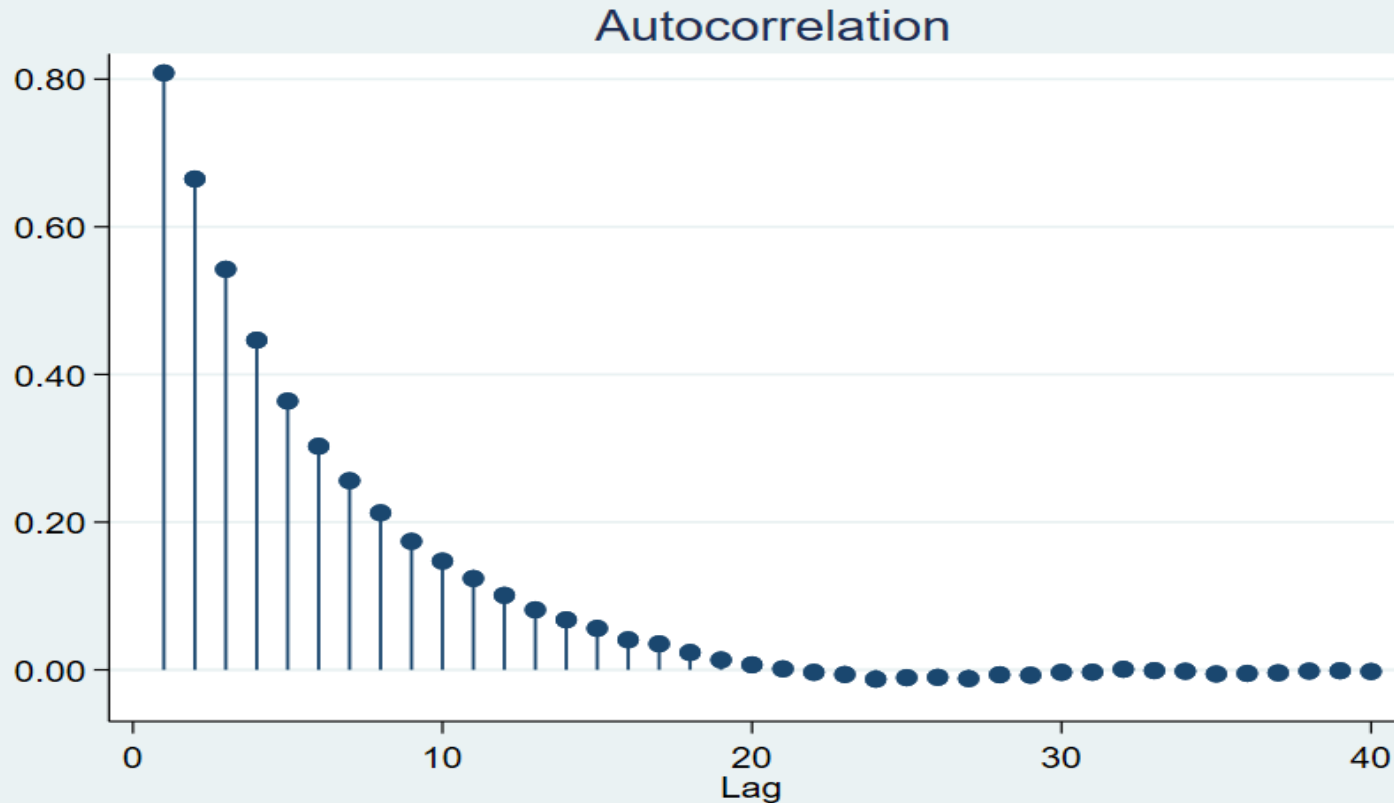
$$\text{Step 3: Draw } u \sim \text{Uniform}(0,1) = 0.233$$

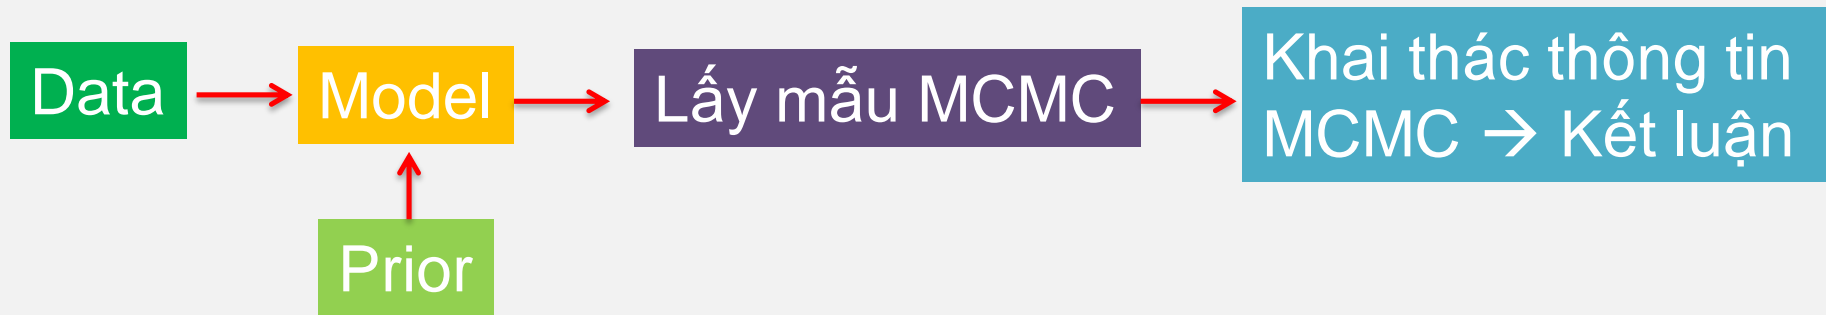
$$\text{Step 4: If } u < \alpha(\theta_{\text{new}}, \theta_{t-1}) \rightarrow \text{If } 0.233 < 0.069 \quad \text{Then } \theta_t = \theta_{\text{new}} = 0.767 \\ \text{Otherwise } \theta_t = \theta_{t-1} = 0.540$$

Burn-in (warm up)



Thinning





Khai thác thông tin từ phân phối hậu nghiệm

$$y = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \varepsilon$$



- ▶ Khai thác thông tin gì từ phân phối này?
- ▶ Point estimates (central tendency)
- ▶ 95%, 99% Credible interval hoặc Highest Density Interval (HDI)

Point estimate

- ▶ Mean hay median hay mode?
- ▶ Hàm loss
 - L_0 : 0/1 loss
 - L_1 : linear loss
 - L_2 : squared loss
- ▶ Chọn chỉ số sao cho loss nhỏ nhất

L_0 : 0/1 loss

$$L_0 i(g) = \begin{cases} 0 & \text{nếu } g = x_i \\ 1 & \text{nếu } g \neq x_i \end{cases}$$

```
(47, 33, 35, 32, 19, 33, 34, 36, 47, 32, 35, 41, 32, 29, 35,  
25, 32, 36, 20, 47, 37, 32, 35, 25, 37, 40, 36, 38, 40, 35, 49,  
23, 33, 35, 38, 28, 36, 4, 28, 45, 37, 39, 34, 41, 28, 33, 27,  
26, 30, 34, 23)
```

```
# mean(x) = 33.45098
```

```
# median(x) = 34
```

```
# mode(x) = 35
```

→ L_0 nhỏ nhất khi g là **mode** của x

L_1 : linear loss

$$L_1(g) = \sum |x_i - g|$$

```
(47, 33, 35, 32, 19, 33, 34, 36, 47, 32, 35, 41, 32, 29, 35,  
25, 32, 36, 20, 47, 37, 32, 35, 25, 37, 40, 36, 38, 40, 35, 49,  
23, 33, 35, 38, 28, 36, 4, 28, 45, 37, 39, 34, 41, 28, 33, 27,  
26, 30, 34, 23)
```

```
# mean(x) = 33.45098
```

```
# median(x) = 34
```

```
# mode(x) = 35
```

→ L_1 nhỏ nhất khi g là **median** của x

```
x <- c(47, 33, 35, 32, 19, 33, 34, 36, 47, 32, 35, 41, 32, 29, 35,  
      25, 32, 36, 20, 47, 37, 32, 35, 25, 37, 40, 36, 38, 40, 35, 49,  
      23, 33, 35, 38, 28, 36, 4, 28, 45, 37, 39, 34, 41, 28, 33, 27,  
      26, 30, 34, 23)  
# mean(x) = 33.45098  
# median(x) = 34  
  
j1 = rep(NA, length(x))  
j2 = rep(NA, length(x))  
for (i in 1:length(x)) {  
  j1[i] = abs(x[i] - mean(x))  
  j2[i] = abs(x[i] - median(x))  
  loss_mean = sum(j1)  
  loss_median = sum(j2)  
}  
loss_mean  
# 284.7451  
loss_median  
# 282
```

L_2 : Squared loss

$$L_2(g) = \sum (x_i - g)^2$$

```
(47, 33, 35, 32, 19, 33, 34, 36, 47, 32, 35, 41, 32, 29, 35,  
25, 32, 36, 20, 47, 37, 32, 35, 25, 37, 40, 36, 38, 40, 35, 49,  
23, 33, 35, 38, 28, 36, 4, 28, 45, 37, 39, 34, 41, 28, 33, 27,  
26, 30, 34, 23)  
# mean(x) = 33.45098  
# median(x) = 34  
# mode(x) = 35
```

→ L_2 nhỏ nhất khi g là **mean** của x

```

x <- c(47, 33, 35, 32, 19, 33, 34, 36, 47, 32, 35, 41, 32, 29, 35,
      25, 32, 36, 20, 47, 37, 32, 35, 25, 37, 40, 36, 38, 40, 35, 49,
      23, 33, 35, 38, 28, 36, 4, 28, 45, 37, 39, 34, 41, 28, 33, 27,
      26, 30, 34, 23)
# mean(x) = 33.45098
# median(x) = 34

j1 = rep(NA, length(x))
j2 = rep(NA, length(x))
for (i in 1:length(x)) {
  j1[i] = (x[i] - mean(x))^2
  j2[i] = (x[i] - median(x))^2
  loss_mean = sum(j1)
  loss_median = sum(j2)
}
loss_mean
# 3124.627
loss_median
# 3140

```



Interval

Equal-tailed Credible Interval (CI)


Hay

Highest Density Interval (HDI)


Equal-tailed Credible Interval



Highest Density Interval



ETI vs. HDI





Kiểm định giả thuyết

Kiểm định giả thuyết

- ▶ Bộ 3:
 - Comp value (ngưỡng so sánh)
 - ROPE (Region of Practical Equivalent)
 - Bayes Factor


CompVal

Ngưỡng so sánh





- ▶ CompVal chia phân phối hậu nghiệm là 2 phần: lớn hơn và bé hơn
- ▶ Ví dụ: phân phối hậu nghiệm của $\theta_1 - \theta_2$ có 95% HDI = -0.223 – 0.545)
- ▶ 79.6% phân phối hậu nghiệm nằm trên ngưỡng 0

ROPE



- ▶ Vùng “vô hiệu” được giới hạn bởi 2 ngưỡng trên-dưới, chia pp hậu nghiệm làm 3 vùng: vùng trong ROPE, vùng lớn hơn, vùng nhỏ hơn
- ▶ 95%HDI nằm **hoàn toàn trong ROPE** được coi như vô hiệu (không có khác biệt, không có hiệu quả...)
- ▶ 95%HDI **nằm hoàn toàn ngoài ROPE** → có hiệu ứng



ROPE = 0.49 - 0.51

- ▶ 95% HDI của $\theta_1 - \theta_2 = 0.491 - 0.509$ nằm hoàn toàn trong ROPE → sự khác biệt không có ý nghĩa trong thực hành
- ▶ 98% pp hậu nghiệm của $\theta_3 - \theta_4$ nằm hoàn toàn ngoài ROPE → θ_3 lớn hơn θ_4 có ý nghĩa trong thực hành

ROPE

- ▶ Tùy thuộc vào lĩnh vực, giả thuyết ...
- ▶ ROPE lấy từ đâu?
 - Bằng chứng từ y văn
 - Ý kiến chuyên gia
 - Kinh nghiệm thực hành
 - ...

Bayes Factor

- ▶ H_1 vs. H_2
- ▶ Giả thuyết nào có khả năng hơn?

$$\text{Posterior odds} = \text{Bayes factor} \times \text{Prior odds}$$

$$PO(H_1:H_2) = \frac{P(H_1 | \text{data})}{P(H_2 | \text{data})}$$

$$= \frac{P(\text{data} | H_1) * P(H_1) / P(\text{data})}{P(\text{data} | H_2) * P(H_2) / P(\text{data})}$$

$$= \frac{P(\text{data} | H_1) * P(H_1)}{P(\text{data} | H_2) * P(H_2)}$$

Bayes factor

Prior odds

$$= \frac{P(\text{data} | H_1)}{P(\text{data} | H_2)} * \frac{P(H_1)}{P(H_2)}$$

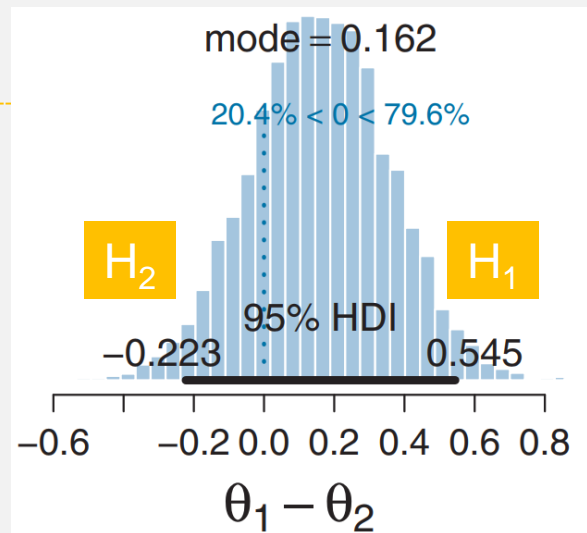
Bayes Factor

Kass and Raftery (1995)

$BF(H_1:H_2)$	$2\log[BF(H_1:H_2)]$	Bằng chứng chống lại H_2
1 - 3	0 - 2	Bare mention
3 - 20	2 - 6	Positive
20 - 150	6 - 10	Strong
> 150	> 10	Very strong

$$H_1: \theta_1 - \theta_2 > 0$$

$$H_2: \theta_1 - \theta_2 < 0$$



- ▶ Posterior odds = $P(H_1|\text{data}) / P(H_2|\text{data}) = 79.6/20.4 = 3.9$
 - ▶ Prior odds = $P(H_1) / P(H_2) \sim 1$
 - ▶ Bayes Factor = Posterior odds / Prior odds = 3.9
- ➔ có bằng chứng cho thấy H_1 có khả năng xảy ra hơn

Một số phần mềm sử dụng trong Bayesian

MCMC sampler

- Dự án BUGS (*Bayesian inference Using Gibbs Sampling*) bắt đầu vào 1989 ở MRC Biostatistics Unit, Cambridge
- ✓ WinBUGS (1997)
- ✓ OpenBUGS
- ✓ MultiBUGS
- JAGS (*Just another Gibbs sampler*) - Martyn Plummer, 2007 – 2017
- Stan - Stan Development Team (đặt theo tên của *Stan*islaw Ulam), 2012 – 2017. Stan sử dụng HMC và NUTS
- Greta (Nick Golding, 2018) được đặt tên theo nhà toán học Grete Hermann (1901 – 1984). Greta sử dụng TensorFlow backend

Phần mềm thống kê

- R
- Python (PyStan, PyMC3)
- SAS
- AMOS
- Mplus
- Stata
-

Thank you !